
Nonparametric Density Estimation II

HYEONWOO YU

Dept. of Intelligent Robotics, SKKU

Outline

- Nonparametric Density Estimation
- Histogram Approach
- Parzen-window method
- K_n -Nearest-Neighbor Estimation
- Gaussian Mixture Models
- Expectation and Maximization

Interim Summary

Histogram

From histogram to density estimation

Convergence conditions

Parzen window

Parzen window Function (Kernel)

Cube kernel, Gaussian kernel

Window size and performance

Classification

K_n – Nearest Neighbor

$$p(\mathbf{x}) \approx \frac{k/n}{V} \quad (*)$$
$$\lim_{n \rightarrow \infty} V_n = 0, \quad \lim_{n \rightarrow \infty} k_n = \infty, \quad \lim_{n \rightarrow \infty} \frac{k_n}{n} = 0$$

$$\lim_{n \rightarrow \infty} p_n(x) = p(x).$$

$$k_n = \sqrt{n}$$

$$V_n \approx 1/(\sqrt{n}p(x))$$



$$p_n(x) = \frac{k_n/n}{V_n}$$

Adaptive window size

K_n – Nearest Neighbor

$$V_n = 1/\sqrt{n}$$

$$k_n = \sum_{i=1}^n \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right)$$



$$p_n(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \frac{1}{V_n} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right).$$

Same window size

Parzen window


Classification with K-NN and Parzen window:

Estimation of a posteriori probabilities

- The k -NN (and Parzen window) techniques can be used to estimate the a posteriori probabilities $p(\omega_i|\mathbf{x})$ from a set of n labeled samples.

- Suppose that we place a cell of volume V around x and capture k samples:

- k_i are labeled ω_i
- $(k - k_i)$ have other labels.



- A simple estimate for the joint probability density $p(\mathbf{x}, \omega_i)$ is

$$p_n(\mathbf{x}, \omega_i) = \frac{k_i / n}{V}$$

- A reasonable estimate for $p(\omega_i|\mathbf{x})$ is

$$p_n(\omega_i|\mathbf{x}) = \frac{p_n(\mathbf{x}, \omega_i)}{\sum_{j=1}^C p_n(\mathbf{x}, \omega_j)} = \frac{k_i}{k}$$


Instance-Based Learning Classifier
Approximated Minimum error classifier

Classification With Nearest Neighbor Rule

- Let $D^n = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ denote a set of n labeled prototypes and let $\mathbf{x}' \in D^n$ be the prototype nearest to a test point $\mathbf{x}$.
- Then **the Nearest Neighbor Rule**: assign the label of $\mathbf{x}'$ to $\mathbf{x}$.
- This rule is suboptimal, but when the number of prototypes is **large**, its error is **never worse** than **twice the Bayes rate**.

Classification With Nearest Neighbor Rule

Voronoi tessellation




Voronoi cells

Classification With the k -Nearest Neighbor Rule

- The k -NN query starts at the test point and grows a spherical region until it encloses k training samples, and it labels by a majority vote of these samples.
- **Algorithm:**
 - For each sample point **Compute Distance** (sample point, test point)
 - **Sort** the distances
 - Inspect the k **smallest** distances
 - Label test point by a **majority vote**.

$$p_n(\omega_i|\mathbf{x}) = \frac{p_n(\mathbf{x}, \omega_i)}{\sum_{j=1}^C p_n(\mathbf{x}, \omega_j)} = \frac{k_i}{k}$$



Classification With the k -Nearest Neighbor Rule

- Question.

- If a *posteriori* probabilities $p(\omega_i | \mathbf{x})$, $i = 1, 2$ for two classes are known, for example



$$p(\omega_1 | \mathbf{x}) > p(\omega_2 | \mathbf{x})$$

- What is a probability of choosing a class ω_1 for x with the Bayes, the nearest neighbor, the k -NN classifiers?

Classification With the k-Nearest Neighbor Rule.

- **Answer**

- Bayes: always w_1
- NN: $p(\omega_1|x)$
- K-NN: $\sum_{i=(k+1)/2}^k \binom{k}{i} p(\omega_1|\mathbf{x})^i (1 - p(\omega_1|\mathbf{x}))^{k-i}$



Exercise

한 해안가에서 연어가 잡힐 확률은 0.6 이고 농어가 잡힐 확률은 0.4 이다.

잡힌 연어 중 40 cm 이하의 크기일 확률은 20%이고,

농어 중 40cm 이하일 확률은 3%이다.

잡은 고기가 40cm 이하 일 때 연어로 분류할 확률을 각각

Bayes, NN, K-NN(K=9) Classifier 에서 구하여라.

답안

$$P(\text{연어}) = 0.6, P(\text{농어}) = 0.4$$

$$P(40\text{cm이하}|\text{연어}) = 0.2, P(40\text{cm이하}|\text{농어}) = 0.03$$

Posteriori probability $P(\text{연어}|40\text{cm이하})$ 와 $P(\text{농어}|40\text{cm이하})$ 를 구하면 다음과 같다.

$$P(\text{연어}|40\text{cm이하}) = \frac{P(40\text{cm이하}|\text{연어})P(\text{연어})}{P(40\text{cm이하})} = \frac{0.2*0.6}{0.6*0.2+0.4*0.03} = 90.9\%$$

$$P(\text{농어}|40\text{cm이하}) = \frac{P(40\text{cm이하}|\text{농어})P(\text{농어})}{P(40\text{cm이하})} = \frac{0.03*0.4}{0.6*0.2+0.4*0.03} = 9.09\%$$

이 posteriori probability를 이용하여 연어로 판정할 확률을 구하면 다음과 같다.

(1) Baye Classifier 의 경우 항상 연어로 분류한다. (100%)

(2) NN의 경우 $P(\text{연어}|40\text{cm이하}) = 90.9\%$ 확률로 연어로 분류한다.

(3) $K=9$ 일 때, $\sum_{i=5}^9 \binom{9}{i} P(\text{연어}|40\text{cm이하})^i (1 - P(\text{연어}|40\text{cm이하}))^{9-i}$ 를 구한다. 따라서

$$14 * (0.909)^5 * (0.0909)^4 + 84 * (0.909)^6 * (0.0909)^3 + 36 * (0.909)^7 * (0.0909)^2 + 9 * (0.909)^8 * (0.0909)^1 + (0.909)^9 * (0.0909)^0 = 0.9937837$$

약 99.4%의 확률로 연어로 분류한다.

Gaussian Mixture Models (GMM)

Gaussian mixture models can be used for –

- Anomaly detection: identifying fraud or detecting errors in data collection
- Probabilistic Labeling
- Generate synthetic data points for data augmentation

In Real-world Scenario

- Finding patterns in medical datasets
- Modeling natural phenomena
- Customer behavior analysis
- Stock price prediction: by volatility and noise detection
- Gene expression data analysis

Goal

Density Estimation (in our case, GMM) with:

- Expectation-Maximization algorithm
- Sampling Method
- Variational Inference

우선은 파라미터에 대한 likelihood를 추정해보자 (이것조차 어려움)


Gaussian Mixture Estimation

- Parzen Window

$$p_n(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \frac{1}{V_n} \phi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right).$$



- Gaussian Mixture

$$p(\mathbf{x}) = \sum_{k=1}^K w_k \varphi\left(\frac{\mathbf{x} - \mu_k}{\sigma_k}\right).$$




Gaussian Mixture Estimation

- 가우시안 분포가 아주 흔하게 사용되는 분포이긴 하지만 현실세계가 그리 만만하지는 않다.
- 현실적으로 가우시안만을 적용하기 어려운 경우가 생겨나기도 한다.
- 아래와 같은 경우의 예제를 생각해보자.



Gaussian Mixture Estimation

- 이러한 문제를 해결하기 위해 이제부터 혼합 가우시안 모델 (Gaussian Mixture Model, GMM) 을 제시한다.
- 가우시안 선형 결합은 매우 복잡한 밀도를 표현할 수 있음
- 충분한 갯수의 가우시안 분포를 사용
- 선형 결합의 계수 뿐만 아니라 평균과 공분산 파라미터를 조절함으로써 거의 대부분의 연속 밀도를 임의의 정확도로 근사 가능함



혼합 가우시안 분포 (Mixture of Gaussians)

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \mu_k, \Sigma_k)$$

- 각각의 가우시안 분포 $N(\mathbf{x} | \mu_k, \Sigma_k)$: component
- 각 분포는 파라미터에 대한 likelihood

물론 일반화된 모델에서는 혼합 모델을 만들 때 서로 다른 분포를 혼합한 모델도 사용 가능 (ex: 베르누이 분포 혼합)

Gaussian Mixture Estimation

- 파라미터 π_k 는 혼합 계수 (mixing coefficient)이다.
- 각각의 컴포넌트들은 정규화 되어있고 (확률이므로) $p(x)$ 도 정규화되어야 하므로 다음을 만족해야 한다.

$$\sum_{k=1}^K \pi_k = 1$$


- 또한 모든 가우시안들은 $N(x|\mu_k, \Sigma_k) \geq 0$ 이므로, $p(x) \geq 0$ 을 만족해야 한다.
- 이런 조건들을 조합하면, 다음을 얻을 수 있다:

$$0 \leq \pi_k \leq 1$$

- 여기서, k^{th} 컴포넌트가 전체 GMM을 구성할 확률(영향력)을 $p(k)$ 라 하자. 그러면 다음과 같은 marginal distribution을 구할 수 있다:

$$p(x) = \sum_{k=1}^K p(k)p(x|k)$$

- 이 식은 당연히 앞서 정의한 GMM $p(x)$ 와 같아야 한다..
- 따라서 $\pi_k = p(k)$ 와 같은 식을 유도할 수 있다. 이는 k^{th} 번째 컴포넌트의 사전 분포로 고려할 수 있다.
- 그러면 확률 밀도는 $p(x|k) = N(x|\mu_k, \Sigma_k)$ 와 같이 생각할 수 있다.



Gaussian Mixture Estimation

- 이제 *responsibilities* 라고 불리는 posteriori $p(k|x)$ 에 대해서 생각해보자 (나중에 쓰임)
- 베이지 룰에 의해 이 사후분포는 다음과 같이 주어진다:

$$\gamma_k(x) \equiv p(k|x) = \frac{p(k)p(x|k)}{\sum_l p(l)p(x|l)} = \frac{\pi_k N(x|\mu_k, \Sigma_k)}{\sum_l \pi_l N(x|\mu_l, \Sigma_l)}$$

- 여기서 GMM 의 파라미터는 π, μ and Σ 이다.
- Parametric estimation과 같이, 이 파라미터들을 구하는 방법은 MLE를 사용하는 것이다.
- 그러면 log-likelihood는 다음과 같이 주어진다:

$$\ln p(X|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(x_n|\mu_k, \Sigma_k) \right\}$$

- 여기서 $X = x_1, x_2, \dots, x_N$ 는 우리가 열심히 모은 학습 데이터일 것이다.
 - 가장 큰 문제는, 위의 식이 log-sum-exp 꼴로 closed-form 해가 없는 꼴이라는 것이다.
 - 따라서 지금까지 해 왔듯이 단순히 미분때려서 최적의 파라미터를 찾을 수가 없다...
-

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X} | \pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

분명 closed-form solution이 없다고 했지만, 그럼에도 불구하고 미분을 해서 구해보자!
MLE를 통해 파라미터 추정 – loglikelihood를 각 파라미터에 대해 편미분

1) M에 대해 편미분

$$0 = - \sum_{n=1}^N \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)} \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X} | \pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

양변에 Σ_k 를 곱하고 전개하면

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$$

$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

- μ 는 마치 샘플 x 에 대한 평균과 같이 구해진다
 - 그러나 responsibilities, 즉 사후 분포 $p(k|x)$ 에 의해 weighted sum과 같이 표현됨
 - 즉 사후 분포에 의해 데이터 x 하나가 k 번째 가우시안 분포에 영향을 미치는 정도가 반영된다
 - 그렇기 때문에 responsibilities라고 이름 붙은 것
-

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

2) 마찬가지로 Σ_k 에 대하여 미분하고 0으로 두어 풀면 아래와 같다:

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

3) 마찬가지로 π_k 에 대하여 미분하고 0으로 두어 푼다.

이 때, $\sum_{k=1}^K \pi_k = 1$ 의 제약이 있었으므로 라그랑지안 방법으로 최적화를 하면

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right)$$

$$0 = \sum_{n=1}^N \frac{N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)} + \lambda$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

3) 마찬가지로 π_k 에 대하여 미분하고 0으로 두어 푼다.

이 때, $\sum_{k=1}^K \pi_k = 1$ 의 제약이 있었으므로 라그랑지안 방법으로 최적화를 하면

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right)$$

$$0 = \sum_{n=1}^N \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)} + \lambda$$

양변에 π_k 를 곱하여 $\gamma(z_{nk})$ 를 만들어주고 풀면 (전개과정 생략)

$$\pi_k = \frac{N_k}{N}$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

$$\pi_k = \frac{N_k}{N}$$


$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

각 파라미터의 최적해가 다른 파라미터의 최적해에 동시에 영향을 받는 형태

- Closed form solution이 없음
- 더 이상 방법이 없나?

EM for Gaussian Mixtures



- 1) Init step
 - 그림 (a)와 같이 임의의 평균 분산으로 초기화 (파라미터 초기화)
- 2) Expectation step
 - 현재 파라미터 값을 이용하여 responsibilities (사후 확률) 계산
- 3) Maximization step
 - Expectation step에서 계산한 사후 확률 값을 이용하여 MLE를 통한 파라미터 다시 추정 (그림 (c))
- 4) 반복 (그림 (d), (e), (f))

GMM에 대한 EM 적용 과정

EM for Gaussian Mixtures

GMM의 log-likelihood

$$\ln p(\mathbf{X}|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

$$\pi_k = \frac{N_k}{N}$$

$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

- E 단계

- 주어진 파라미터 값들을 이용하여 responsibility 값을 계산한다.

$$\gamma(z_{nk}) = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

- M 단계

- 주어진 responsibility 값을 이용하여 파라미터를 추정한다.

$$\mu_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$$

$$\Sigma_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

$$\pi_k^{new} = \frac{N_k}{N}$$

$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

Interim Summary

- K_n -Nearest Neighbor Method
 - Nearest Neighbor Method
 - k -Nearest Neighbor Method
 - k -Nearest Neighbor Classifier
 - Bayes, the nearest neighbor, the k-NN classifiers
 - Gaussian Mixture Model
 - EM Algorithm
-