
Variational Inference

HYEONWOO YU

Dept. of Intelligent Robotics, SKKU

Outline


- GMM with Latent variables
- Variational Inference

GMM with Latent Variables

혼합 가우시안 분포 (Mixture of Gaussians)

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \mu_k, \Sigma_k)$$

- GMM 모델링에는 K 차원을 가지는 binary random variable $\mathbf{z}$ 를 도입할 수 있다
- 단순히 k번째 가우시안 컴포넌트(클러스터)가 미치는 영향력 혹은 개입 정도를 나타내는 random variable이라고 생각하자
- Random variable $\mathbf{z}$ 는 K-dim random variable
- ex) $\mathbf{z} = \{1, 0, 0, \dots, 0, 0\}$
- 각 element는 각 가우시안 클러스터를 선택하느냐 마느냐를 나타낸다고 생각하자
- 이때 각 가우시안 클러스터가 선택될 확률이 π_k 라고 하자
- ex) $p(\mathbf{z} = \{1, 0, 0, \dots, 0, 0\}) = \pi_1$
- $p(\mathbf{z} = \{0, 1, 0, \dots, 0, 0\}) = \pi_2$



GMM with Latent Variables

혼합 가우시안 분포 (Mixture of Gaussians)


$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \mu_k, \Sigma_k)$$

- ex) $\mathbf{z} = \{1, 0, 0, \dots, 0, 0\}$
- ex) $p(\mathbf{z} = \{1, 0, 0, \dots, 0, 0\}) = \pi_1$
- $p(\mathbf{z} = \{0, 1, 0, \dots, 0, 0\}) = \pi_2$
- 종합하면 latent random variable $\mathbf{z}$ 는 다음과 같은 성질을 가진다

$$p(z_k = 1) = \pi_k$$

$$0 \leq \pi_k \leq 1$$

$$\sum_{k=1}^K \pi_k = 1$$



GMM with Latent Variables

- 그러면 latent variable $\mathbf{z}$ 에 대해 다음과 같은 확률분포를 사용할 수 있다

$$p(z_k = 1) = \pi_k$$

$$p(\mathbf{z}) = \prod_{k=1}^K \pi_k^{z_k}$$


$$p(\mathbf{x}|z_k = 1) = N(\mathbf{x}|\mu_k, \Sigma_k)$$

$$p(\mathbf{x}|\mathbf{z}) = \prod_{k=1}^K N(\mathbf{x}|\mu_k, \Sigma_k)^{z_k}$$

- 이 때 $\mathbf{x}$ 에 대한 marginal distribution은 다음과 같다:

$$p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{z})p(\mathbf{x}|\mathbf{z}) = \sum_{k=1}^K \pi_k N(\mathbf{x}|\mu_k, \Sigma_k)$$

- 결국 원래의 GMM식과 같이 된다




GMM with Latent Variables

$$p(z_k = 1) = \pi_k$$

$$p(\mathbf{z}) = \prod_{k=1}^K \pi_k^{z_k}$$

$$p(\mathbf{x}|z_k = 1) = N(\mathbf{x}|\mu_k, \Sigma_k)$$

$$p(\mathbf{x}|\mathbf{z}) = \prod_{k=1}^K N(\mathbf{x}|\mu_k, \Sigma_k)^{z_k}$$



Latent variable을 도입하여 정의한 위의 확률분포를 이용하여, datapoint $\mathbf{x}$ 가 주어졌을 때의 사후확률 (responsibilities)를 계산해볼 수 있다

$$\gamma(z_k) \equiv p(z_k = 1|\mathbf{x}) = \frac{p(z_k = 1)p(\mathbf{x}|z_k = 1)}{\sum_{j=1}^K p(z_j = 1)p(\mathbf{x}|z_j = 1)} = \frac{\pi_k N(\mathbf{x}|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(\mathbf{x}|\mu_j, \Sigma_j)}$$

GMM with Latent Variables

Latent variable을 도입한 likelihood의 EM algorithm 일반화

만약 $\mathbf{X}$ 및 $\mathbf{Z}$ 가 모두 관측되었다면 log likelihood는 다음과 같다

$$\ln p(\mathbf{X}, \mathbf{Z} | \theta)$$

그러나 많은 경우 latent variable $\mathbf{Z}$ 는 관측되지 못하기 때문에, latent variable이 일어날 수 있는 모든 경우를 모두 고려하여 아래와 같이 marginal distribution을 얻는다:

$$\ln p(\mathbf{X} | \theta) = \ln \left\{ \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} | \theta) \right\}$$

- 잠재 변수를 포함한 분포가 log 안에서 합으로 표현 (log-sum)
 - Joint probability가 exponential family를 따른다고 하더라도 이와 같이 구한 marginal distribution은 exponential family를 따르지 않는다
 - 간단한 quadratic function을 따르는 함수 형태로 나타내어지지 못한다
 - 복잡한 MLE풀이가 동반됨
-

GMM with Latent Variables

$$\ln p(\mathbf{X}|\theta) = \ln \left\{ \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta) \right\}$$

위의 복잡한 형태를 갖는 marginal distribution을 사용해서 MLE를 구하는 것이 힘들기 때문에, 아래와 같은 Expectation of loglikelihood 함수를 사용하고자 한다 (왜?):

$$E_Z[\ln p(\mathbf{X}, \mathbf{Z}|\theta)] = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

이 Expectation of log-likelihood에 Expectation-Maximization 방법을 적용하여 MLE를 수행, 최적의 파라미터를 찾을 수 있다

GMM with Latent Variables

Latent variable을 도입한 likelihood의 EM algorithm

$$\ln p(\mathbf{X}|\theta) = \ln \left\{ \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta) \right\}$$

E-step

- 우선 모든 파라미터를 constant라고 하고, 이를 θ^{old} 라고 하자
- 여기서 latent variable $\mathbf{Z}$ 에 대한 확률 $p(\mathbf{Z}|\mathbf{X}, \theta^{old})$ 를 계산

$$E_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z}|\theta)] = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

$$Q(\theta, \theta^{old}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

GMM with Latent Variables

Latent variable을 도입한 likelihood의 EM algorithm

$$\ln p(\mathbf{X}|\theta) = \ln \left\{ \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta) \right\}$$

E-step

- 우선 모든 파라미터를 constant라고 하고, 이를 θ^{old} 라고 하자
- 여기서 latent variable $\mathbf{Z}$ 에 대한 확률 $p(\mathbf{Z}|\mathbf{X}, \theta^{old})$ 를 계산

$$E_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z}|\theta)] = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

$$Q(\theta, \theta^{old}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

M-step

- 예측한 $\mathbf{Z}$ 의 사후분포 확률을 이용해서 Q 를 최대화하는 파라미터를 구한다

$$\theta^{new} = \arg \max_{\theta} Q(\theta, \theta^{old})$$

GMM with Latent Variables

Latent variable을 도입한 likelihood의 EM algorithm

EM 알고리즘 일반화

- 관찰데이터 $\mathbf{X}$ 와 잠재 변수 $\mathbf{Z}$ 가 파라미터 θ 에 의해 주어졌을 때,
- 결합 분포는 $p(\mathbf{X}, \mathbf{Z}|\theta)$ 와 같이 표현 가능하다.
- 이 때 $p(\mathbf{X}|\theta)$ 값을 가장 크게 만드는 파라미터 θ 값을 얻고 싶다. (MLE를 이용)
 - **Init Step** : (임의의) 파라미터 θ^{old} 의 값을 설정한다.
 - **E-Step** : $p(\mathbf{Z}|\mathbf{X}, \theta^{old})$ 값을 추론한다.
 - **M-Step** : θ^{new} 값을 추론한다. 이 때,
 - $\theta^{new} = \arg \max_{\theta} Q(\theta, \theta^{old})$
 - $Q(\theta, \theta^{old}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$
 - 새롭게 구해진 파라미터의 값들이 수렴 상태인지 확인한다.
 - 수렴되지 않았다면 아래 작업 후 Step-2 로 돌아간다.
 - 수렴되었을 경우 종료한다.
 - $\theta^{old} \leftarrow \theta^{new}$

$$\ln p(\mathbf{X}|\theta) = \ln \left\{ \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta) \right\}$$

$$E_Z[\ln p(\mathbf{X}, \mathbf{Z}|\theta)] = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

GMM revisited

혼합 가우시안 분포 (Mixture of Gaussians)

$$\ln p(\mathbf{X}|\mu, \Sigma, \pi) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

위 식에서 latent variable은 직접적으로 나타나지 않으나, latent variable을 도입하여 EM algorithm을 수행할 수 있다


1) E-step: 확률 $p(\mathbf{Z}|\mathbf{X}, \theta^{old})$ 를 계산

$$p(\mathbf{Z}|\mathbf{X}, \mu, \Sigma, \pi) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)]^{z_{nk}}$$

where

$$p(\mathbf{z}) = \prod_{k=1}^K \pi^{z_k}$$

$$p(\mathbf{x}|\mathbf{z}) = \prod_{k=1}^K N(\mathbf{x}|\mu_k, \Sigma_k)^{z_k}$$



GMM revisited

혼합 가우시안 분포 (Mixture of Gaussians)

$$\ln p(\mathbf{X}|\mu, \Sigma, \pi) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$


위 식에서 latent variable은 직접적으로 나타나지 않으나, latent variable을 도입하여 EM algorithm을 수행할 수 있다

2) M-step: 최적 파라미터 구하기

$$Q(\theta, \theta^{old}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

$$\theta^{new} = \arg \max_{\theta} Q(\theta, \theta^{old})$$

$$Q(\theta, \theta^{old}) = E_{\mathbf{Z}} [\ln p(\mathbf{X}, \mathbf{Z}|\mu, \Sigma, \pi)] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \{ \ln \pi_k + \ln N(\mathbf{x}_n | \mu_k, \Sigma_k) \}$$



GMM revisited

$$\begin{aligned} E_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z}|\theta)] &= E_{\mathbf{Z}}\left[\sum_n \ln p(\mathbf{x}_n, \mathbf{z}_n|\theta)\right] = \sum_n E_{\mathbf{Z}}[\ln p(\mathbf{x}_n, \mathbf{z}_n|\theta)] \\ &= \sum_{n=1}^N E_{\mathbf{Z}}[\ln(p(\mathbf{z}_n)p(\mathbf{x}_n|\mathbf{z}_n, \theta))] = \sum_{n=1}^N E_{\mathbf{Z}}\left[\ln\left[\prod_{k=1}^K (\pi_k N(\mathbf{x}_n|\mu_k, \Sigma_k))^{z_{nk}}\right]\right] \\ &= \sum_{n=1}^N \sum_{k=1}^K E_z[(z_{nk}) \ln(\pi_k N(\mathbf{x}|\mu_k, \Sigma_k))] = \sum_{n=1}^N \sum_{k=1}^K E_z[z_{nk}] \ln(\pi_k N(\mathbf{x}_n|\mu_k, \Sigma_k)) \\ &= \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \{\ln \pi_k + \ln N(\mathbf{x}_n|\mu_k, \Sigma_k)\} \end{aligned}$$

$$\begin{aligned} p(\mathbf{z}) &= \prod_{k=1}^K \pi^{z_k} \\ p(\mathbf{x}|\mathbf{z}) &= \prod_{k=1}^K N(\mathbf{x}|\mu_k, \Sigma_k)^{z_k} \end{aligned}$$

$$E_Z[\ln p(\mathbf{X}, \mathbf{Z}|\theta)] = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

where

$$\begin{aligned} E[z_{nk}] &= \frac{\sum_{\mathbf{z}_n} z_{nk} \prod_{k'} [\pi_{k'} N(\mathbf{x}_n|\mu_{k'}, \Sigma_{k'})]^{z_{nk'}}}{\sum_{\mathbf{z}_n} \prod_j [\pi_j N(\mathbf{x}_n|\mu_j, \Sigma_j)]^{z_{nj}}} \\ &= \frac{\pi_k N(\mathbf{x}_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(\mathbf{x}_n|\mu_j, \Sigma_j)} = \gamma(z_{nk}) \end{aligned}$$

GMM revisited

$$Q(\theta, \theta^{old}) = E_{\mathbf{Z}} [\ln p(\mathbf{X}, \mathbf{Z} | \mu, \Sigma, \pi)] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \{ \ln \pi_k + \ln N(\mathbf{x}_n | \mu_k, \Sigma_k) \}$$

이제 이 식에 대해 MLE를 수행하면 (각 파라미터에 대해 미분하여 해를 구하면) 다음과 같이 된다:

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

$$\pi_k = \frac{N_k}{N}$$

Outline

- GMM with Latent variables
- Variational Inference

Variational Inference

Latent variable Z 를 가진 모델의 데이터 X 가 주어졌을 때, marginal distribution은 다음과 같이 주어진다:

$$p(\mathbf{X}|\theta) = \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta)$$

- Discrete latent variable의 경우는 위와 같이 sum으로 표현
- Continuous latent variable의 경우 integral

이제 갑자기, 아주 뜬금없이, latent variable Z 에 대한 확률분포 $q(Z|\theta')$ 를 제안한다.
이때 이 확률분포 $q(Z|\theta')$ 가 다음 조건을 만족하는 경우를 생각해보자

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

Variational Inference

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

Where

$$L(q, \theta) = \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\}$$
$$KL(q||p) = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z}|\mathbf{X}, \theta)}{q(\mathbf{Z})} \right\}$$

- 위의 두 식은 범함수 (functional)은 함수들의 집합을 정의역으로 갖는 함수이다.
(ex: entropy, KL-divergence, Fourier transform 등)
 - 그러나 L의 경우, 파라미터 θ 에 대해서는 실수를 입력으로 하여 실수를 반환하는 일반함수
 - $L(\theta; q)$ 로도 나타냄
-

Variational Inference

Prior knowledge

- **Jensen's Inequality** (옌슨 부등식)

- 만약 $f(x)$ 가 **convex** 를 만족한다면 다음이 항상 성립한다.

$$E[f(x)] \geq f(E[x])$$

- **Gibb's Inequality** (깁스 부등식)

- 함수 q 와 p 에 대해 $KL[p||q] \geq 0$ 을 항상 만족한다.

- (참고) 만약 $p = q$ 이면 $KL[p||q] = 0$

- (참고) 만약 $p \neq q$ 이면 $KL[p||q] > 0$

- (증명) $KL[p||q] = \sum_i p_i \ln \frac{p_i}{q_i} = - \sum_i p_i \ln \frac{q_i}{p_i} \geq - \ln[\sum_i p_i \frac{q_i}{p_i}] = - \ln[\sum_i q_i] = 0$

Variational Inference

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

Where

$$L(q, \theta) = \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\}$$

$$KL(q||p) = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z}|\mathbf{X}, \theta)}{q(\mathbf{Z})} \right\}$$

Variational Inference

$$\ln p(\mathbf{X}|\theta) = \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta)$$

이제 새로운 확률밀도함수 $q(\mathbf{z})$ 를 도입하여, 다음과 같이 표현할 수 있다:

$$\ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta) = \ln \sum_{\mathbf{Z}} q(\mathbf{Z}) \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \geq \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} = L(q, \theta)$$

**Jensen's
Inequality**

이와 같이 얻은 $L(\theta; q)$ 는 log likelihood $\ln p(\mathbf{X}|\theta)$ 의 lower bound (Evidence Lower BOund, ELBO)가 된다 (왜?)

Variational Inference

ELBO가 되는 이유를 알아보기 위해, log likelihood $\ln p(\mathbf{X}|\theta)$ 와 $L(\theta; q)$ 의 차이를 계산해보자:

$$\begin{aligned}\ln p(\mathbf{X}|\theta) - L(q, \theta) &= \ln p(\mathbf{X}|\theta) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} \\ &= \ln p(\mathbf{X}|\theta) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z}|\mathbf{X}, \theta)p(\mathbf{X}|\theta)}{q(\mathbf{Z})} \right\} \\ &= \ln p(\mathbf{X}|\theta) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z}|\mathbf{X}, \theta)}{q(\mathbf{Z})} \right\} - \ln p(\mathbf{X}|\theta) \sum_{\mathbf{Z}} q(\mathbf{Z}) \\ &= - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z}|\mathbf{X}, \theta)}{q(\mathbf{Z})} \right\} = KL[q(\mathbf{Z}) \| p(\mathbf{Z}|\mathbf{X}, \theta)] = KL[q \| p]\end{aligned}$$

이항하여 정리하면

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q \| p) \geq L(\theta; q)$$

**Gibb's
Inequality**

Variational Inference

$$\begin{aligned}\ln p(\mathbf{X}|\theta) &= L(q, \theta) + KL(q||p) \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \theta)]\end{aligned}$$

Variational Inference

$$\begin{aligned}\ln p(\mathbf{X}|\theta) &= L(q, \theta) + KL(q||p) \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z}) || \boxed{p(\mathbf{Z}|\mathbf{X}, \theta)}]\end{aligned}$$


Posterior of
Latent variables

Variational Inference

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

$$= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z}) || p(\mathbf{Z}|\mathbf{X}, \theta)]$$

Posterior of
Latent variables




Variational Inference

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

$$= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z}) || p(\mathbf{Z}|\mathbf{X}, \theta)]$$

Posterior of
Latent variables

- Variational inference의 의미는 근사하기 힘든 latent variable의 posterior를 근사할 수 있는 $q(\mathbf{Z}|\theta')$ 함수를 찾는 것



Variational Inference

$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$


$$= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z}) || p(\mathbf{Z}|\mathbf{X}, \theta)]$$

Posterior of
Latent variables

- Variational inference의 의미는 근사하기 힘든 latent variable의 posterior를 근사할 수 있는 $q(\mathbf{Z}|\theta')$ 함수를 찾는 것

- 구하기 힘든 posterior와 직접 KL을 계산하지 않고, 계산하기 쉬운 ELBO의 최대화를 통해 $q(\mathbf{Z}|\theta')$ 를 근사적으로 찾는 것이 variational inference의 핵심

- 물론 KL을 직접 계산하는 것이 더 쉽다면 ELBO를 계산하지 않아도 된다



Variational Inference

$$\begin{aligned}\ln p(\mathbf{X}|\theta) &= L(q, \theta) + KL(q||p) \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \theta)]\end{aligned}$$

- ELBO를 전개하여 정리하면
다음과 같다:

$$\begin{aligned}L(q, \theta) &= ELBO = \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(X, Z|\theta)}{q(Z)} \right\} \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(X|Z, \theta)p(Z)}{q(Z)} \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(X|Z, \theta) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{q(Z)}{p(Z)} \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(X|Z, \theta) - KL(q(Z)||p(Z))\end{aligned}$$

- 여기서 $q(Z|\theta')$ 뿐만 아니라, $p(X|Z, \theta)$ 와 $p(Z)$ 도 모르는 경우 (파라미터 θ 를 모르는 경우)는 어떻게 해야할까? MLE라도 써야하나?
 - => EM 알고리즘 사용
-


$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

Variational Inference

$$= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \theta)]$$

E-step

- KL-divergence term부터 최소로 만드는 것이 목표
- 이 단계에서는 파라미터 θ 를 고정한다 (θ^{old})
- $L(\theta; q)$ 의 두 변수 중 θ 가 고정된 상태라고 생각할 수 있다
- 즉 E-step에서는, $L(\theta^{old}; q)$ 를 최대화하는 q (posterior $p(\mathbf{z}|\mathbf{x})$)를 근사하는) 를 추정하는 단계로 볼 수 있다



$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$


$$= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \theta)]$$

Variational Inference

E-step

- KL-divergence term부터 최소로 만드는 것이 목표
- 이 단계에서는 파라미터 θ 를 고정한다 (θ^{old})
- $L(\theta; q)$ 의 두 변수 중 θ 가 고정된 상태라고 생각할 수 있다
- 즉 E-step에서는, $L(\theta^{old}; q)$ 를 최대화하는 q (posterior $p(z|x)$ 를 근사하는) 를 추정하는 단계로 볼 수 있다

$$KL(q||p) = 0$$



$$\ln p(\mathbf{X}|\theta) = L(q, \theta) + KL(q||p)$$

$$= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \right\} + KL[q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \theta)]$$


Variational Inference

E-step

- KL-divergence term부터 최소로 만드는 것이 목표
- 이 단계에서는 파라미터 θ 를 고정한다 (θ^{old})
- $L(\theta; q)$ 의 두 변수 중 θ 가 고정된 상태라고 생각할 수 있다
- 즉 E-step에서는, $L(\theta^{old}; q)$ 를 최대화하는 q (posterior $p(z|x)$ 를 근사하는) 를 추정하는 단계로 볼 수 있다

- GMM 에서는 posterior가 다행히도 계산 가능하므로, 여기서는 $q(\mathbf{Z}|\theta')$ 를 새로 정의해서 θ' 를 찾을 필요도 없이 $q = p(z|x, \theta^{old})$ 로 선택하게 된 것이다

$$KL(q||p) = 0$$



$$p(\mathbf{Z}|\mathbf{X}, \mu, \Sigma, \pi) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)]^{z_{nk}}$$

Variational Inference

M-step


- 이 단계에서는 $p(z|x, \theta^{old})$ 를 이용해서 아래를 풀었다:

$$Q(\theta, \theta^{old}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$$

$$\theta^{new} = \arg \max_{\theta} Q(\theta, \theta^{old})$$

이 과정을 ELBO와 연관하여 생각해 보면,
 q 를 고정시킨 상태에서 ELBO를 maximize할 수 있는
새로운 파라미터 θ^{new} 를 추정하는 것과 같다

$$\text{KL}(q||p) = 0$$



Variational Inference

M-step

- 정리하면 다음과 같다:



$$q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \theta^{old})$$

$$L(q, \theta) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{X}, \mathbf{Z}|\theta) - \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{old}) \ln p(\mathbf{Z}|\mathbf{X}, \theta^{old}) = Q(\theta, \theta^{old}) + H(p)$$



- 위와 같이 Expectation of log가 등장
 - 이 때문에 EM for GMM에서 다루기 힘들었던 log-sum 대신 Expectation of log를 사용하는 것과 같이 설명하였던 것
 - 즉 Expectation of log를 사용한 기본적인 이유는 이것이 variational inference에 기반한 방법이었기 때문
-

Variational Inference

$$\text{KL}(q||p) = 0$$



Variational Inference



Variational Inference

variational inference의 목적:

- 근사하기 힘든 latent variable의 posterior $p(Z|X, \theta)$ 를 근사할 수 있는 $q(Z|\theta')$ 함수를 찾는 것
- 일반적으로는 $q(Z|\theta')$ 를 uni-modal gaussian과 같이 간단한 함수로 가정하여 근사
- GMM과 같은 경우는 posterior의 직접 계산이 가능하였기 때문에 이를 그대로 q 로 이용

의의:

- 확률 분포 추정 문제를 최적화 문제로 변환
 - deterministic한 solution 제공 (global solution은 보장할 수 없음)
-
- 더욱 복잡한 확률분포를 추정하기 위해 더 복잡한 $q(Z|\theta')$ 를 사용할 수 없는가?
 - $p(Z|X, \theta)$ 는 data X 와 연관되어 있는데, q 또한 X 를 고려하여 근사할 수 있을까?

Interim Summary

- Latent variables and GMM
- Variational Inference