

ROB5016 Reinforcement Learning: Homework 1

Submission Deadline: 11:59PM, May 29th, 2025

Department: 지능로봇공학

Student ID: 2025711391

Name: 송영국

In Lecture 7, the policy gradient is derived from the value function $V^\pi(s)$, leading to the following form:

$$\nabla_\theta V^\pi(s) \approx \frac{1}{m} \sum_{i=1}^m \left(\sum_{t=0}^{T-1} R(\tau^{(i)}) \nabla_\theta \log \pi_\theta(a_t^{(i)} | s_t^{(i)}) \right) \quad (1)$$

Here, the value function $V^\pi(s)$ can be expressed in terms of the Q-function as follows:

$$V^\pi(s) = \sum_a \pi_\theta(a|s) Q^\pi(s, a) \quad (2)$$

Assuming the initial state $s = s_0$ is fixed, we define the policy objective function $J(\theta)$ as:

$$J(\theta) := V^\pi(s_0) = \sum_a \pi_\theta(a|s_0) Q^\pi(s_0, a) \quad (3)$$

Questions

1. Compute the exact gradient $\nabla_\theta J(\theta)$ of the above expression using the product rule. Include all differentiable terms.
2. Compare your result to the following policy gradient formula introduced on Slide p.44 of Lecture 7:

$$\nabla_\theta J(\theta) = \sum_a \pi_\theta(a|s_0) \nabla_\theta \log \pi_\theta(a|s_0) Q^\pi(s_0, a) \quad (4)$$

If your result does not match, identify what assumption or approximation is required to make the two expressions agree. Discuss under what conditions this approximation can be justified in practice.

Answer 1.

수식 3번에서 시작해보자.

$$J(\theta) = V^\pi(s_0) = \sum_a \pi_\theta(a|s_0) Q^\pi(s_0, a)$$

여기서 $\nabla_\theta J(\theta)$ 를 표현하면 다음과 같이 쓸 수 있다.

$$\begin{aligned} \nabla_\theta J(\theta) &= \nabla_\theta \left(\sum_a \pi_\theta(a|s_0) Q^\pi(s_0, a) \right) \\ &= \sum_a \nabla_\theta (\pi_\theta(a|s_0) Q^\pi(s_0, a)) \end{aligned}$$

이때, $\nabla_\theta (\pi_\theta(a|s_0) Q^\pi)$ 에 곱의 미분법을 적용하면,

$$\nabla_\theta (\pi_\theta(a|s_0) Q^\pi(s_0, a)) = \nabla_\theta \pi_\theta(a|s_0) \cdot Q^\pi(s_0, a) + \pi_\theta(a|s_0) \cdot \nabla_\theta Q^\pi(s_0, a)$$

으로 정리되는데, 우변의 첫번째 항에 로그 미분 트릭을 적용하면, 첫번째 항을 아래와 같이 바꿔 쓸 수 있다.

$$\begin{aligned} \nabla_\theta \pi_\theta(a|s_0) \cdot Q^\pi &= \pi_\theta(a|s_0) \nabla_\theta \log \pi_\theta(a|s_0) \cdot Q^\pi(s_0, a) \\ &\left(\because \nabla_\theta \log \pi_\theta(a|s_0) = \frac{\nabla_\theta \pi_\theta(a|s_0)}{\pi_\theta(a|s_0)} \right) \end{aligned}$$

곱의 미분과, 로그 미분트릭을 모두 적용한 $\nabla_\theta J(\theta)$ 는 다음과 같다.

$$\nabla_\theta J(\theta) = \sum_a [\pi_\theta(a|s_0) \nabla_\theta \log \pi_\theta(a|s_0) \cdot Q^\pi(s_0, a) + \pi_\theta(a|s_0) \cdot \nabla_\theta Q^\pi(s_0, a)]$$

Answer 2.

문제의 식 4번과 수식이 일치하지 않는 이유는, Policy Gradient Theorem 에서 앞의 1번 답 식의 두번째 항 중 $\nabla_\theta Q^\pi(s_0, a)$ 을 0으로 근사하기 때문이다.

이 근사(Approximation)이 타당하려면,

- $\nabla_\theta Q^\pi(s, a)$ 이 작거나 무시가 가능할때,
- $Q^\pi(s, a)$ 이 변화가 없을때
- Baseline과 같은 기법을 적용한 경우,
- On-Sampling 기법을 사용할 경우