

Answer 1.

수식 3번에서 시작해보자.

$$J(\theta) = V^\pi(s_0) = \sum_a \pi_\theta(a|s_0) Q^\pi(s_0, a)$$

여기서 $\nabla_\theta J(\theta)$ 를 표현하면 다음과 같이 쓸 수 있다.

$$\begin{aligned} \nabla_\theta J(\theta) &= \nabla_\theta \left(\sum_a \pi_\theta(a|s_0) Q^\pi(s_0, a) \right) \\ &= \sum_a \nabla_\theta (\pi_\theta(a|s_0) Q^\pi(s_0, a)) \end{aligned}$$

이때, $\nabla_\theta (\pi_\theta(a|s_0) Q^\pi)$ 에 곱의 미분법을 적용하면,

$$\nabla_\theta (\pi_\theta(a|s_0) Q^\pi(s_0, a)) = \nabla_\theta \pi_\theta(a|s_0) \cdot Q^\pi(s_0, a) + \pi_\theta(a|s_0) \cdot \nabla_\theta Q^\pi(s_0, a)$$

으로 정리되는데, 우변의 첫번째 항에 로그 미분 트릭을 적용하면, 첫번째 항을 아래와 같이 바꿔 쓸 수 있다.

$$\begin{aligned} \nabla_\theta \pi_\theta(a|s_0) \cdot Q^\pi &= \pi_\theta(a|s_0) \nabla_\theta \log \pi_\theta(a|s_0) \cdot Q^\pi(s_0, a) \\ &\left(\because \nabla_\theta \log \pi_\theta(a|s_0) = \frac{\nabla_\theta \pi_\theta(a|s_0)}{\pi_\theta(a|s_0)} \right) \end{aligned}$$

곱의 미분과, 로그 미분트릭을 모두 적용한 $\nabla_\theta J(\theta)$ 는 다음과 같다.

$$\nabla_\theta J(\theta) = \sum_a [\pi_\theta(a|s_0) \nabla_\theta \log \pi_\theta(a|s_0) \cdot Q^\pi(s_0, a) + \pi_\theta(a|s_0) \cdot \nabla_\theta Q^\pi(s_0, a)]$$

Answer 2.

문제의 식 4번과 수식이 일치하지 않는 이유는, Policy Gradient Theorem 에서 앞의 1번 답 식의 두번째 항 중 $\nabla_\theta Q^\pi(s_0, a)$ 을 0으로 근사하기 때문이다.

이 근사(Approximation)이 타당하려면,

- $\nabla_\theta Q^\pi(s, a)$ 이 작거나 무시가 가능할때,
- $Q^\pi(s, a)$ 이 변화가 없을때
- Baseline과 같은 기법을 적용한 경우,
- On-Sampling 기법을 사용할 경우